

Ficha Técnica do Projeto de Dados

Análise de Performance de Músicas no Spotify e Plataformas Concorrentes

Objetivo

Desenvolver uma base analítica consolidada para avaliar o desempenho de músicas no Spotify e em plataformas concorrentes, permitindo análises sobre popularidade, presença em rankings, playlists e tendências musicais.

O projeto teve como objetivo realizar o processo completo de preparação dos dados, incluindo profiling, limpeza, padronização, enriquecimento e integração de múltiplas fontes para posterior construção de dashboards e geração de insights.

Ferramentas e Tecnologias

Armazenamento e Processamento

- Google BigQuery

Linguagem

- SQL (GoogleSQL)

Visualização

- Looker Studio

Controle de Qualidade dos Dados

- Data Profiling
 - Tratamento de valores nulos
 - Padronização de categorias
 - Conversão de tipos de dados
 - Deduplicação de registros
-

Contexto dos Dados

O projeto utiliza duas fontes principais:

1. Dados do Spotify

Tabela original:

`track_in_spotify_ativa_BR`

Contém informações sobre:

- Identificador da música (`track_id`)
 - Nome da música
 - Nome do artista
 - Quantidade de artistas participantes
 - Gênero musical principal
 - País principal
 - Número de streams
 - Presença em playlists do Spotify
 - Presença em rankings do Spotify
 - Data de lançamento
-

2. Dados de Plataformas Concorrentes

Tabela original:

`track_in_competition_ativa_BR`

Contém indicadores de presença das músicas em:

- Apple Music Playlists
 - Apple Music Charts
 - Deezer Playlists
 - Deezer Charts
 - Shazam Charts
-

Processamento e Análises

Etapas 1 – Data Profiling dos Dados do Spotify

Foi realizada uma análise exploratória inicial para avaliar a qualidade dos dados.

Principais verificações realizadas:

Duplicidades

Foram identificados registros duplicados de `track_id`.

Decisão adotada:

- Manter apenas um registro por música.
 - Utilizar a música com maior quantidade de streams como registro válido.
-

Valores Nulos

Foram encontrados:

Campo	Quantida de
main_music_genre	1
main_country	1
in_spotify_charts	4

Tratamentos realizados:

- Preenchimento manual dos campos ausentes para o registro identificado pelo `track_id = 4796316`.
 - Valores nulos de `in_spotify_charts` foram considerados como ausência no ranking e substituídos por 0.
-

Padronização de Categorias

Foram identificadas inconsistências de nomenclatura:

Gênero Musical

Original	Padronizado
----------	-------------

Disco pop	Disco-pop
-----------	-----------

País

Original	Padronizado
----------	-------------

MX	Mexico
----	--------

PR	Puerto Rico
----	-------------

USA United States

Conversão de Tipos

Foram encontrados valores armazenados como texto em campos numéricos.

Tratamentos:

- Conversão de `track_id` para STRING.
 - Conversão de `in_spotify_playlists` para INT64 utilizando `SAFE_CAST`.
-

Validação de Datas

Foi realizada validação dos campos:

- `released_year`
- `released_month`
- `released_day`

Posteriormente foi criada uma coluna de data consolidada:

`released_date`

Utilizando:

`SAFE.DATE(released_year, released_month, released_day)`

Etapa 2 – Criação da Tabela Limpa do Spotify

Tabela criada:

`track_in_spotify_clean`

Principais transformações:

- Remoção de duplicidades
 - Padronização de categorias
 - Tratamento de nulos
 - Conversão de tipos
 - Criação de data completa
-

Etapa 3 – Data Profiling dos Dados de Concorrência

Foi realizada análise da tabela:

`track_in_competition_ativa_BR`

Principais verificações:

Unicidade

Foi validado que os registros possuíam chave única baseada em `track_id`.

Resultado:

- Nenhuma duplicidade encontrada.
-

Valores Nulos

Foi identificado:

Campo	Quantidade
in_shazam_charts	50

Análise realizada:

- Comparação com a base Spotify através de JOIN.
 - Verificação dos registros ausentes.
-

Validação de Valores Negativos

Foram realizadas verificações para identificar possíveis valores inválidos em:

- Apple Playlists
- Apple Charts
- Deezer Playlists
- Deezer Charts
- Shazam Charts

Nenhuma inconsistência relevante foi identificada.

Etapa 4 – Criação da Tabela Limpa de Concorrência

Tabela criada:

`track_in_competition_clean`

Tratamentos aplicados:

- Conversão segura para inteiro utilizando `SAFE_CAST`.
- Substituição de valores nulos em `in_shazam_charts` por 0.

Exemplo:

```
IFNULL(SAFE_CAST(in_shazam_charts AS INT64), 0)
```

Etapa 5 – Integração das Bases

Foi criada uma tabela analítica consolidada:

`track_performance`

Integração realizada através de:

`LEFT JOIN`

entre:

- `track_in_spotify_clean`
- `track_in_competition_clean`

utilizando:

`track_id`

Estrutura Final da Base Analítica

A tabela consolidada passou a conter:

Identificação

- `track_id`
- `track_name`
- `artists_name`

Características da Música

- `artist_count`
- `main_music_genre`
- `main_country`

Indicadores Spotify

- in_spotify_streams
- in_spotify_playlists
- in_spotify_charts

Indicadores Apple Music

- in_apple_playlists
- in_apple_charts

Indicadores Deezer

- in_deezer_playlists
- in_deezer_charts

Indicadores Shazam

- in_shazam_charts

Informações Temporais

- released_year
 - released_month
 - released_day
 - released_date
-

Resultados e Conclusões

Qualidade dos Dados

O processo de limpeza permitiu:

- Eliminar registros duplicados.
 - Corrigir inconsistências de categorização.
 - Padronizar países e gêneros.
 - Tratar valores nulos.
 - Garantir tipagem adequada dos campos.
-

Base Analítica Consolidada

Foi construída uma tabela única contendo indicadores de performance de múltiplas plataformas musicais.

Essa estrutura possibilita análises como:

- Evolução dos lançamentos ao longo dos anos.

- Comparação entre Spotify, Apple Music, Deezer e Shazam.
 - Identificação dos gêneros mais populares.
 - Avaliação de artistas com maior alcance.
 - Análise de presença em rankings e playlists.
 - Construção de dashboards executivos no Looker Studio.
-

Limitações / Próximos Passos

Limitações

- Os dados representam uma fotografia estática do período disponibilizado.
- Não há histórico temporal de streams e rankings.
- Algumas correções de valores nulos foram realizadas manualmente com base na observação dos registros.

Próximos Passos

- Criar testes automatizados de qualidade dos dados.
 - Construir pipeline de atualização automática.
 - Adicionar documentação de dados (Data Dictionary).
 - Expandir análises para tendências temporais e segmentação por gênero musical.
-

Links de Interesse

Repositório do Projeto

https://drive.google.com/drive/folders/1SN4VNyDHBC7w8YV8b1ntyiNZIEXP8HKw?usp=drive_link

Dashboard Looker Studio

<https://datastudio.google.com/reporting/d59f11b1-1d5e-42c6-8381-94e592002e0e>

Dataset

Projeto BigQuery:

[my-first-project-494602](#)

Dataset:

[spotify](#)

Tabelas Geradas

- `track_in_spotify_clean`
 - `track_in_competition_clean`
 - `track_performance`
-

Resumo Executivo

O projeto consistiu na construção de uma camada analítica para avaliação de desempenho musical em plataformas de streaming. Foram executadas etapas de profiling, limpeza, padronização, tratamento de inconsistências e integração de dados provenientes do Spotify e de plataformas concorrentes. Como resultado, foi criada uma tabela analítica consolidada capaz de suportar dashboards, análises exploratórias e futuras iniciativas de Business Intelligence.